

실험 설계 이해 — 파일럿 → 선별 → 본실험

2026-09-15 랩미팅 발표자료 (교수님 프로토콜

2026-09-11 판 기준)

09-08 순서도 1판은 폐기 — 09-11 변경(결정 29·30) 반영판

작성: 2026-09-12 · 곽동신 (서버 클로드 정리)

- ① 순서도 그림 + 5분 발표 대본 + 예상 질문 + 교수님께 여쭙 것 4개
- ② 교수님 설계를 쉬운 말로 풀어 쓴 정리 (11절)
- ③ 같은 과제를 GPT·로컬 클로드·딥시크·제미나이에게 시켜 대조한 결과

근거: platform/planning/안내.md · 260905_00·01·02·05·06 · 260906_파일럿_단계_및_결정규칙.md

04_experiments/260911_파일럿0/README.md (2026-09-11 수정본)

곽동신 · 2026-09-12

블루베리 세그멘테이션 연구 · 안홍렬 교수님 연구실

이 책의 차례

1 순서도와 발표 대본

그림 한 장, 5분 대본, 예상 질문 11개, 교수님께 여쭙 것 4개

2 교수님 설계 쉬운 말 정리

무엇이 바뀌었나, 데이터 분할, 단계별 결정 권한, 선별 규칙, 평가, 미정 항목

3 외부 AI 4개 대조

GPT·로컬 클로드·딥시크·제미나이 결과를 원문 기준으로 비교한 결과


1장

순서도와 발표 대본

교수님이 "이해한 바대로 설명해 보라"고 하신 것. 그림을 먼저 보고 대본을 읽는다.

실험 설계 순서도 2판 (2026-09-12)

회색 = 완료(이력) · 노랑 테두리 = 실행 중 · 주황 = 파일럿 · 초록 = 본실험 · 보라 = 산출



실험 설계 순서도 2판 — 파일럿 → 선별 → 본실험

런 수: $P\ 2,304 + M1\ 576 + M2\sim M5\ 192\sim 368 = 3,072\sim 3,248$ 런. $C1\ 48 + \text{파일럿}\ 0\ 64$ 포함 $3,184\sim 3,360$. $C0$ (옛 6런)은 별도.

2. 발표 대본 (5분, 쉬운 말)

왜 이렇게 하나 (30초)

- 헤더 12개와 백본 12개를 전부 짝지으면 144개 조합입니다. 4개 데이터셋에서 5-fold 로 다 돌리면 2,880런이라 못 합니다.
- 그래서 "작은 데이터로 먼저 거르고, 전체 데이터는 한 번만 돌리고, 유망한 것만 다섯 번 돌린다"는 3단계 설계입니다.

1단계 — 데이터를 둘로 나눈다 (40초)

- 각 데이터셋을 20%와 80%로 한 번만 나눕니다. 20%는 파일럿, 80%는 본실험입니다. 파일럿은 본실험에 절대 다시 안 씁니다. 고르는 데이터와 평가하는 데이터를 분리하는 게 핵심입니다.
- 블루베리로 치면 파일럿 239장, 본실험 956장입니다. 본실험은 다시 M1~M5 다섯 조각입니다.
- 바뀌지 않은 것도 말씀드리면, 20%·80% 소속과 본실험 M1~M5, 그룹 묶음은 그대로이고 파일럿 안쪽만 다시 나눴습니다.
- 파일럿 안은 지난 금요일(09-11)에 4분할로 바뀌었습니다. 회전마다 학습 2조각, 검증 1조각, 시험 1조각입니다. 검증은 체크포인트를 고르는 데, 시험은 점수를 재는 데 씁니다. 3-fold 때는 검증 하나로 둘 다 했는데 이제 분리했습니다. 데이터셋당 4회전이래 모든 조각이 시험 한 번, 검증 한 번 씁니다.

2단계 — 언제 멈출지 정한다: C1 과 파일럿0 (60초)

- 2,304런을 돌리기 전에 "몇 epoch 에서 멈출지"를 정해야 합니다. 대표 4쌍으로만 미리 재는 단계입니다. 대표는 고전 디코더 BackboneUNet 과 최신 디코더 VWFormer, CNN 백본 ResNet-50 과 Transformer 백본 MiT-B2 를 교차한 4쌍입니다.
- C1 은 옛 3-fold 로 48런을 300 epoch 끝까지 돌린 것이고 지난주에 끝났습니다. 결과는 fast 규칙(40 지나고 10 epoch 안 좋아지면 멈춤)이 standard(80 지나고 40)보다 놓친 IoU 가 중앙값 0.0085 로 작지만, 복숭아 한 런에서는 0.604 로 컸습니다. 작은 데이터셋은 늦게 좋아집니다.
- 그래서 교수님이 파일럿0 를 추가하셨습니다. 같은 4쌍을 새 4분할로 64런, 800 epoch 까지 끝까지 돌리면서 매 epoch 검증과 시험 점수를 둘 다 기록합니다. 그리고 그저께 일요일(09-13) 새벽 0시 11분에 64런을 전부 다시 시작하셨습니다(결정 31). 첫 판은 best 와 800 epoch 체크포인트 두 개만 남겨서 "몇 epoch 예산까지 하면 성능이 유지되는가"를 판정할 가중치가 없었기 때문입니다. 새 판은 100, 200, ... 800 epoch 경계마다 그 구간까지의 최고 검증 모델을 따로 저장합니다(런당 8개). 그 체크포인트들을 나중에 전체 영상 슬라이딩으로 한 번씩 평가해서 예산을 정합니다. 어제(09-14) 오후에 64런이 [★ 발표 전 확인: 서버 클로드에게 "파일럿0 집계"

요청 → "모두 끝났습니다 / ○○런 끝났습니다" 로 채울 것]. 시험 점수는 기록만 하고 아무것도 고르지 않습니다. (일요일 정오 시점 진행은 8/64, 완주 예상은 월요일(09-14) 오후 1시에서 4시 사이(마지막 GPU 약 오후 4시)였습니다.)

- 여기서 나온 성적은 후보 고르는 데 안 씁니다. 파일럿0는 멈춤 규칙과 체크포인트 규칙을 동결할 재료를 모으는 단계이고, 이걸로 정확히 무엇을 결정할지는 교수님 문서에 아직 "미정"으로 돼 있습니다.

3단계 — P: 파일럿으로 거른다 (60초)

- 144조합을 파일럿 안에서 4회전 돌립니다. $144 \times 4 \times 4 = 2,304$ 런입니다.
- 회전마다 검증 조각으로 체크포인트를 고르고, 시험 조각의 Dice 로 점수를 냅니다. 데이터셋마다 4회전 평균, 4개 데이터셋은 똑같은 무게로 평균합니다. 포도가 2,502장이라고 점수를 지배하면 안 되니까요. 속도나 메모리는 점수에 안 넣습니다.
- 고르는 규칙은 두 줄입니다. A = 헤더마다 가장 잘 맞는 백본 하나, B = 백본마다 가장 잘 맞는 헤더 하나, C = A 와 B 를 합친 것. 헤더 12개와 백본 12개가 전부 최소 한 번씩 들어가고, 겹치니까 12개에서 23개 사이입니다.
- 파일럿이 끝나면 C 를 잠급니다.

4단계 — M1: 전체를 한 번 (30초)

- 144조합 전부를 본실험 80%로 한 번씩 돌립니다. M2~M5 로 학습하고 M1 로 시험합니다. 576런입니다. 모든 조합이 같은 시험지를 푼다. M1 결과를 보고 C 를 바꾸면 안 됩니다.

5단계 — M2~M5: 유망한 것만 다섯 번 (30초)

- C 에 든 12~23개만 나머지 4개 fold 를 더 돌립니다. $16 \times |C| = 192 \sim 368$ 런입니다.
- 승자가 둘 나옵니다. Full-grid winner 는 144개 전체의 M1 1등, Cross-validated winner 는 C 안의 5-fold 1등입니다. 최종 권장은 후자입니다. 둘이 다르면 왜 다른지를 보고합니다.

마무리 (20초)

- 벤치마크 런 수는 3,072~3,248런입니다(P 2,304 + M1 576 + M2~M5 192~368). 여기에 C1 48 과 파일럿0 64 를 더한 신규 전체는 3,184~3,360런이고, 파일럿 쪽이 2,416런, 본실험 쪽이 768~944런입니다. 144개를 그냥 5-fold 로 다 돌리면 2,880런인데, 그 대신 이 설계는 후보 C 에만 5-fold 를 씁니다. test 는 전체 영상 슬라이딩 윈도우로 한 번만 평가하고, 통계는 짝지은 비교에 다중비교 보정, 블록은 데이터셋 4개입니다.
- 이 설계가 답하는 질문은 넷입니다. 어떤 조합을 추천할 것인가, 좋은 백본은 디코더가 바뀌어도 좋은가, 성능이 부품의 합인가 궁합인가, 최신 기법의 이득이 작고 뻑뻑하고 겹친 과실에서도 재현되는가.

3. 예상 질문과 답

3-0. 발표 끝에 교수님께 여쭙볼 것 4개 (문서끼리 어긋나는 곳 — "이해한 바대로" 설명하면서 확인받기)

- **결정 13(VMamba-T 동결) 상태** — 안내.md 표에는 "13 미결"인데 00 문서 § 4 에는 "해소(v2 s1l8, SHA-256, backend 동결)"로 돼 있습니다. 정본 규칙(충돌 시 00 우선)대로 해소로 이해했는데 맞는지.
- **P 선별 점수를 재는 fold** — 결정 16·파일럿 문서 § 4 는 "시험 fold Dice(체크포인트는 검증 fold)"인데 00 § 1 본문은 "파일럿 validation Dice"라고 돼 있습니다. 4분할 이후 시험 fold 가 맞다고 이해했습니다.
- **복숭아 파일럿 학습 장수** — 01 문서 § 3 은 회전당 12~13장(v3 실측)인데 06 문서 § 4 는 "약 17장"(3-fold 시절)입니다. 12~13 이 현행이라고 이해했습니다.
- **파일럿0 로 무엇을 결정하나** — 파일럿 문서 § 1 표에는 "미정, 사용자 확정 필요"로 남아 있는데, 09-13 결정 31 은 "몇 epoch 예산까지 하면 성능이 유지되는가를 구간별 체크포인트의 전체영상 슬라이딩 시험 지표로 판정한다"고 적혀 있습니다. 그래서 파일럿0 의 결정 사항 = ① epoch 예산(100~800 중 어디까지) ② 조기종료·체크포인트 규칙, 이렇게 이해했는데 맞는지. § 1 표의 "미정"은 낡은 것인지.

3-1. 설계 질문

- "3-fold 를 왜 4분할로 바꿨나" → 파일럿 안에서 체크포인트 고르는 데이터와 점수 재는 데이터를 분리하려고요(결정 29). 대신 회전당 학습 표본이 파일럿의 2/3 에서 2/4 로 줄었습니다. 복숭아는 회전당 학습 12~13장입니다.
- "파일럿0 로 뭘 정하나" → 결정 31(09-13)로 목적이 분명해졌습니다. epoch 100, 200, ... 800 경계마다 그 구간까지의 최고 검증 모델을 저장해 두고, 나중에 전체 영상 슬라이딩으로 한 번씩 평가해서 "몇 epoch 예산이면 충분한가"를 정합니다. 매 epoch 시험 점수는 센터크롭 모니터링일 뿐 프로토콜 지표가 아닙니다. 조기종료 규칙과 체크포인트 규칙도 여기서 확정된 뒤 P 전에 동결한다고 이해했습니다.
- "파일럿0 중간 결과는" → [★ 09-14 저녁 집계로 갱신할 것. 아래는 일요일 정오 8/64 기준] 포도 MiT-B2 두 조합(BackboneUNet·VWFormer × 4회전) 8런 기준으로, 구간별 체크포인트의 센터크롭 시험 Dice 가 100 epoch 예산 0.939~0.957 에서 800 epoch 예산 0.944~0.956 으로 차이가 최대 0.006 입니다. 즉 포도 MiT-B2 는 100 epoch 뒤 이득이 거의 없습니다. 다만 센터크롭 값이고 프로토콜 판정은 전체영상 슬라이딩으로 다시 합니다. 첫 판(폐기)에서는 블루베리 best 가 728·740 처럼 늦게 나온 회전이 있어 데이터셋마다 다를 수 있습니다.
- "C1 은 버리나" → 아닙니다. 이력으로 보존합니다. 다만 3-fold 라 학습 표본 비율이 다르고 epoch 예산도 달라서 4분할 수치와 직접 비교하지 않습니다.
- "2,304런은 얼마나 걸리나" → [추정] 아직 추정도 못 합니다. 교수님도 "C1·파일럿0 실측으로 재산정"이라 두셨습니다. 파일럿0 가 끝나면 800 epoch 실측이 나오니 그때 계산합니다. 참고로 파일럿0 64런은 약 262 GPU시간 추정이었습니다.
- "지금 실행을 막고 있는 건" → 파일럿0 v2 완주(월요일 낮)와 그 뒤 validation process 동결입니다. 코드는 슬라이딩 윈도우 추론이 파일럿0 코드 폴더에 생겼고(O-1 [완료], 다만 03_code 에는 미반영), 평가 증강 함수의 두 분기가 모두 CenterCrop 인 문제(O-9, augmentations.py:340)와 foreground-aware sampling(O-6)이 아직 없습니다. 그리고 파일럿 이후 단계의 GPU 시간이 전부 재산정 대상입니다.
- "아직 안 정해진 설정은" → weight decay, warm-up 길이, 최대 update 수(복숭아와 포도가 20배 차이라 epoch 대신 update 로 맞추지), seed 개수, BN 처리, gradient clipping, 실패 판정. 전부 P 전에 동결합니다.

- "test 는 어떻게 평가하나" → 전체 영상 슬라이딩 윈도우 512, stride 384, threshold 0.5 고정, TTA·후처리 없음. 영상 단위 Dice. test 는 프로토콜과 C 가 동결된 뒤에만 엽니다. 센터크롭은 과실의 75~77% 를 못 봐서 최종 평가엔 안 씁니다.
- "왜 144개를 5-fold 다 안 하나" → 2,880런이라서요. 대신 144개 전부 M1 에서 같은 시험을 보고 C 만 5-fold 로 확증합니다. 논문엔 "전체 5-fold"라고 쓰지 않습니다.
- "C 를 줄인 이유가 통계 검출력인가" → 아닙니다. 계산량·두 축 대표성·설명 단순성입니다.
- "파일럿 성적으로 고르면 결과 의존 아닌가" → 파일럿 20%는 본실험에서 완전히 빠져 있습니다. 후보 144개 자체는 성능 없이 문헌·구조·재현성으로 골랐습니다.
- "복숭아 125장은 너무 적지 않나" → 맞습니다. 가중치는 그대로 두고 복숭아 순위 vs 나머지 3개의 Kendall τ 로 순위 안정성을 보고합니다(결정 19).
- "효율은 안 보나" → 봅니다. 파라미터·FLOPs·VRAM·속도를 144개 전부 보고하되 점수에는 안 넣습니다(결정 20).

4. 숫자 출처

- 결정 12·14~16·19·20·24~30 — platform/planning/260905_00_프로토콜_관리원칙.md
- 런 수 2,304 / 576 / 192~368 / 3,072~3,248 — platform/planning/안내.md (2026-09-11)
- 분할 장수 — platform/planning/260905_01_데이터_및_분할.md § 3 (v3_seed3407 실측)
- 파일럿0 v2 진행 8/64, 구간별 체크포인트 값 —
platform/04_experiments/260911_파일럿0/runs_v2/*/budget_checkpoints.json ·
pilot0_summary.json (2026-09-13 12시). 결정 31 —
platform/planning/260905_00_프로토콜_관리원칙.md § 3. 완주 예상 — launcher_v2/gpu*.queue ×
실측 epoch 초 + 런당 부대시간 861초(gpu*.log START→DONE 실측)
- C1 regret —
platform/04_experiments/260908_파일럿/reports_c1_center_v1/c1_calibration_report.json

2장

교수님 설계 쉬운 말 정리

발표 대본의 교과서. 막히는 개념이 있으면 여기서 찾는다.

교수님 실험 설계 — 쉬운 말로

0. 한 문장

"헤더 12개 × 백본 12개 = 144개 조합을, 데이터의 20%로 먼저 거르고, 나머지 80%에서 전부 한 번 + 유망한 것만 다섯 번 평가한다."

1. 2026-09-11 에 바뀐 것 (지난주 순서도와 다른 점)

항목	지난주(09-08)	지금(09-11 이후)
파일럿 안 나누는 법	3-fold (학습 2 / 검증 1)	4분할 (학습 2 / 검증 1 / 시험 1) — 결정 29
회전 수	데이터셋당 3회	데이터셋당 4회
C1 (48런, 300 epoch)	완주(교수님 문서 표기 09-07 완료, 마지막 체크포인트 파일 시각 09-08 09:46)	완주. 이제 " 이력 "(옛 3-fold라 새 설계와 직접 비교 안 함)
새 단계	없음	파일럿0 = 대표 $2 \times 2 \times 4$ 데이터셋 × 4회전 = 64런, 800 epoch 완주 — 결정 30. 첫 판 09-11 17:27 시작 → 폐기, 09-13 00:11 v2 재시작 (결정 31)
P 선별 런 수	1,728	2,304 ($144 \times 4 \times 4$)
전체 런 수	2,496~2,672	3,072~3,248 (파일럿0·C1 포함 3,184~3,360)
GPU 상태	8장 유휴	8장 전부 교수님 파일럿0 실행 중
파일럿0 체크포인트 (09-13 결정 31)	best 1개 + final 1개 (첫 판)	구간별 8개 checkpoint_best_within_{100..800}.pth + best + final. 첫 판(32런 완주)은 폐기·보존, 09-13 00:11 에 64런 전부 재실행(v2)

왜 4분할로 바꿨나: 파일럿 안에서도 "체크포인트 고르는 데이터(검증)"와 "점수 재는 데이터(시험)"를 분리하려고. 3-fold 때는 검증 fold 하나로 둘 다 했다. 대신 회전당 학습 표본이 파일럿의 $2/3 \rightarrow 2/4$ 로 줄었다.

2. 데이터를 어떻게 나누나 (결정 12·29)

데이터셋	전체	파일럿 20%	파일럿 회전당 학습/검증/본실험 80%	M1~M5 한 조각
블루베리	1,195	239	119~120 / 59~60 / 59~60 956	191
사과	1,001	200	82~118 / 41~66 / 41~66 801	160
복숭아	125	25	12~13 / 6~7 / 6~7 100	20
포도	2,502	500	250 / 125 / 125 2,002	400

- 파일럿 20%는 **본실험에 절대 다시 안 쓴다**. 고르는 데이터와 평가하는 데이터를 완전히 분리하기 위해.
- 같은 나무·같은 영상·연속 프레임은 같은 쪽에 둔다(블루베리 = Camera N Video (M), 사과 = 촬영 시퀀스). 포도·복숭아는 그룹 정보가 없어 장 단위.
- 옛 실험(C0)에서 validation 으로 본 복숭아 23장·포도 250장은 그룹째 파일럿에 넣고 prior_validation_exposure=true 로 표시. 본실험에 안 들어간다.
- 분할 파일: platform/04_experiments/260908_파일럿/protocol_splits/v3_seed3407/ (seed 3407). v2(3-fold)는 C1 이력용.
- 회전 규칙: 시험 fold t, 검증 fold t+1(순환), 나머지 2개로 학습. 그래서 모든 fold 가 시험 1번·검증 1번 쓰인다.

3. 단계 (앞이 열기 전에 뒤를 열리지 않는다)

- ① 12×12 동결 + 144조합 스모크 [완료] 2026-09-08 (144/144 PASS)
 - ② 20/80 분할 + 파일럿 4분할(v3) hash .. [완료] 2026-09-11
 - ③ 공통 학습 설정 고정 (loss·LR·seed) ... 일부 미정 (weight decay·warm-up·update 예산 등)
 - ④ C1 대표 2×2 × 4데이터셋 × 3fold, 300ep = 48런 ... [완료] 완주 (이력; 교수님 문서 표기 2026-09-07 완료, 파일 시각 09-08 09:46)
 - ④' 파일럿0 대표 2×2 × 4데이터셋 × 4회전, 800ep = 64런 ... v2 재실행 중 (09-13 00:11 시작, 09-13 12시 기준 8/64 완료, 완주 예상 09-14)
 - ⑤ validation process 동결 (조기종료 규칙·체크포인트 규칙) ... 파일럿0 끝난 뒤
 - ⑥ P 144조합 × 4데이터셋 × 4회전 = 2,304런 → C 동결 ...
 - ⑦ frozen/ 에 설정·코드·가중치·분할 hash 기록 ...
- ↓ 본실험
- M1 144조합 전부, 학습 M2UM3UM4UM5 → 시험 M1 = 576런
- M2~M5 C(12~23개)만 나머지 4-fold 추가 = 16×|C| = 192~368런

각 단계가 "정하는 것" (파일럿 문서 § 1 표)

단계	무엇을 정하나	성능 보고 골라도 되는 것	규모
C0	코드·규칙 1차 점검	없음	옛 6런 × 200ep (완료)
C1	fast 조기종료가 후기 개선을 놓치나	조기종료 규칙	48런 (완료, 이력)
파일럿0	800 epoch 간 궤적에서 검증·시험이 어떻게 움직이나, 자원은 얼마나 드나. 09-13 결정 31: 구간별(100~800) 최고 검증 체크포인트를 전체영상 슬라이딩으로 평가해 "몇 epoch 예산이면 충분한가" 판정	파일럿 문서 § 1 표는 아직 "미정"(낮은 듯) · 결정 31 로는 epoch 예산 + 조기종료·체크포인트 규칙	64런 (v2 재실행 중)
P	144조합에서 C 를 고른다	C = A ∪ B 만	2,304런
M1	144조합 공통 순위·주효과·상호작용	없음	576런
M2~M5	C 의 fold 안정성	없음	192~368런

4. C1 이 알려준 것 (실측; 교수님 문서 표기 2026-09-07 완료, 마지막 체크포인트 파

- 규칙 두 개를 같은 궤적에 사후 적용: standard = 80 epoch 지나고 40 epoch 안 좋아지면 멈춤 / fast = 40 지나고 10.
- fast 가 standard 보다 놓친 IoU(regret): 중앙값 0.0085, 평균 0.032, **최악 0.604**(복숭아 VWFormer×ResNet-50 fold2: fast 42ep 에 멈췄는데 standard 는 175ep 에서 훨씬 좋아짐).
- 데이터셋별 중앙값: 포도 0.003 · 사과 0.007 · 블루베리 0.017 · 복숭아 0.030. 작은 데이터셋일수록 늦게 좋아진다.
- standard 는 평균 164 epoch, fast 는 63 epoch 에서 멈춤. 런당 1.72시간, 합계 82 GPU시간.
- 교수님이 이걸로 규칙을 확정하지 않고 **파일럿0(800 epoch)**를 추가하셨다. 300 epoch 로는 후기 개선을 다 못 본다고 판단하신 것으로 보인다([추정] 내 추정, 문서엔 "사용자 지시"라고만 있음). 그리고 09-13 에 파일럿0 를 **구간별 체크포인트를 남기는 v2 로 재실행**(결정 31)하셨다. 이유는 문서에 명시: "몇 epoch 예산까지 하면 성능이 유지되는가"를 프로토콜 시험 지표(전체영상 슬라이딩)로 판정하려면 구간별 최고 검증 모델의 가중치가 필요한데 첫 판은 best·final 2개만 저장했기 때문.

5. 파일럿0 v2 가 지금까지 보여주는 것 (2026-09-13 12시, 8/64 완료분 — 포도 Mi

결정 31 로 런마다 epoch 100·200·……·800 경계에서 "그 구간까지의 최고 검증 모델"이 저장된다. 그 모델의 센터크롭 시험 Dice 를 예산별로 보면 "몇 epoch 이면 충분한가"가 보인다(단, 프로토콜 판정은 전체영상 슬라이딩으로 다시 한다).

포도 (v2)	전체 best epoch	검증 Dice @best	시험 Dice @예산100	@예산300	@예산800	100→800 이득
BackboneUNet × MiT-B2 t1v2	511	0.950	0.943	0.943	0.945	+0.002
BackboneUNet × MiT-B2 t2v3	375	0.958	0.945	0.945	0.949	+0.005
BackboneUNet × MiT-B2 t3v4	517	0.957	0.957	0.954	0.956	-0.001
BackboneUNet × MiT-B2 t4v1	516	0.948	0.953	0.954	0.955	+0.002
VWFormer × MiT-B2 t1v2	315	0.950	0.939	0.945	0.944	+0.004
VWFormer × MiT-B2 t2v3	121	0.958	0.947	0.946	0.946	-0.001
VWFormer × MiT-B2 t3v4	272	0.954	0.953	0.955	0.955	+0.002
VWFormer × MiT-B2 t4v1	189	0.945	0.949	0.955	0.955	+0.006

읽는 법: 포도 MiT-B2 는 **100 epoch 예산 뒤 이득이 최대 0.006** 이다. 전체 best epoch 는 121~517 로 흩어지지만 그 차이가 시험 Dice 로는 거의 안 나타난다. 이걸 센터크롭 값이고 포도 한 데이터셋·백본 하나뿐이다. 포도 ResNet-50 2조합 8런(지금 실행 중, 일요일 저녁 완료 예상)과 블루베리·사과·복숭아는 월요일 오후에 나온다.

첫 판(09-11, 폐기·보존, runs/)에서 봤던 것: 포도는 best 가 300 을 넘는 회전이 많았고 best 와 800 시점의 시험 Dice 차이는 0.01 안쪽. 블루베리 VWFormer×MiT-B2 는 best 가 728·740 처럼 낮고 한 회전은 800 시점이 best 보다 0.026 낮았다(0.912→0.886). 사과는 검증 fold 가 41~66장이라 검증 Dice 가 0.660 까지 흔들렸다. **첫 판 숫자는 발표에서 인용하지 말 것**(교수님이 "쓰지 않는다"고 명시). 첫 판 telemetry 로 교수님이 만든 구간별 표는 reports/260913_구간별_최대검증_시험Dice_센터크롭.csv.

발표 때는 "v2 실행 중, 포도 MiT-B2 만 8런 끝났고 100 epoch 뒤 이득이 0.006 이하, 결론은 완주 후"로 말할 것.

6. P 선별 규칙 (결정 14~16)

- 144조합 × 4데이터셋 × 4회전 = 2,304런. 검증 fold 로 체크포인트 고르고, **시험 fold** 의 image-macro Dice 로 점수.
- 데이터셋마다 4회전 평균 → 4데이터셋 **동일 가중** 평균(포도가 점수를 지배하지 못하게).
- A = 헤더마다 1등 백본(12개), B = 백본마다 1등 헤더(12개), C = A ∪ B. $12 \leq |C| \leq 23$. 동점은 ID 사전순.
- 효율(속도·메모리)은 점수에 안 넣는다(결정 20). 복숭아 순위 vs 나머지 3개의 Kendall τ 를 보고(결정 19).
- P 끝나면 C 를 잠근다. M1 결과 보고 바꾸지 않는다(결정 25).

7. 본실험과 승자 돌

- M1: 144조합 전부 같은 시험지(M1). "Full-grid winner" = 여기 1등.
- M2~M5: C 만 나머지 4 fold 추가 → C 는 5-fold OOF 완성. "Cross-validated winner" = 여기 1등 = **논문의 실무 최종 권장**.
- 둘이 다르면 분할 의존성·pilot→main 순위 변화·데이터셋 이질성·상호작용·C 의 M1 top-k 포착률을 보고.

8. 평가 방법 (06 문서)

- test 는 **전체 영상 슬라이딩 윈도우** 512, stride 384(25% 겹침), threshold 0.5 고정, TTA·후처리 없음. 지표는 영상 단위로 계산(image-macro Dice 주 지표).
- 센터크롭은 학습 중 검증(매 epoch)과 효율 측정에만 쓴다. 이유: 센터크롭은 과실의 75~77% 를 아예 못 본다(실측).
- 통계: paired 비교 + 다중비교 보정이 주. Friedman 은 보조, 블록 = 데이터셋 4개.
- 슬라이딩 윈도우 추론 코드(O-1)는 09-13 안내.md 기준 "[**완료**] 있음" — 04_experiments/260911_파일럿0/코드/semseg/eval/sliding.py(C0 전체영상 궤적에 사용). 단 03_code 에는 미반영. (09-12 판에 "0건"이라 쓴 것은 낡은 안내.md 를 본 것.) 내 브랜치 kwak/slide-inference-0827 과의 관계는 확인 필요.

9. 아직 안 정해진 것 (발표 때 "미정"이라고 말할 것)

- 파일럿0 로 무엇을 결정할지 — 파일럿 문서 § 1 표는 미정이지만 결정 31(09-13)로 "epoch 예산 판정"이 명시됨. 표가 낡은 것인지 교수님께 확인
- weight decay · warm-up 길이 · 최대 update 수(복숭아 125 vs 포도 2,502 가 20배라 epoch 대신 update 로 맞출지) · seed 개수 · BN 처리 · gradient clipping · 실패 판정(NaN·OOM 재시작 횟수)
- 슬라이딩 중첩 결합(확률 평균 vs logit 평균) · inference batch size
- GPU 시간 재산정(C1·파일럿0 실측으로)

9-1. 문서끼리 어긋나는 곳 3 (외부 AI 대조에서 확인, 2026-09-12)

어디	낡은 문장	현행
안내.md 결정대장 표	"13 미결"	00 § 4: 해소(v2 s1l8) — 00 우선
00 § 1 본문	"파일럿 validation Dice 로 C 선정"	결정 16·파일럿 § 4: 시험 fold Dice, 체크포인트는 검증 fold
06 § 4 복숭아 진단	"학습분 약 17장"	01 § 3: 회전당 12~13장

둘(00 § 1 본문·06 § 4)은 09-11 4분할 변경 전 문장이 남은 것이고, 안내.md "13 미결"은 09-08 VMamba-T 해소(00 § 4)가 표에 반영되지 않은 것. 교수님께 알려드릴 것.

10. 논문에 쓰면 안 되는 말 (안내.md "잇으면 안 되는 것")

- 후보 선정에 본실험 성능을 썼다 (X) (CCASeg 때 실제로 적발됨)
- C 를 줄인 이유가 "통계 검출력" (X) → 계산량·축 대표성·설명 단순성
- 144조합 M1 순위 = C 의 5-fold 순위 (X) → 둘을 구분
- "전체 데이터 5-fold CV" (X) → "20% exclusive pilot; 144 on common M1 holdout; pilot-selected C with five-fold OOF"
- "전수조사(exhaustive survey)" (X) → candidate audit / scoping review

11. 이 설계가 답하려는 질문 넷 (교수님 02 § 5)

- 어떤 조합을 추천할 것인가
- 좋은 백본은 디코더가 바뀌어도 좋은가 (주효과)
- 성능이 부품의 합인가 궁합인가 (상호작용)
- 최신 기법의 이득이 작고·많고·겹친 과실에서도 재현되는가

3장

외부 AI 4개 대조

같은 원문·같은 프롬프트로 독립적으로 풀게 한 뒤 원문 기준으로 대조. 내가 제대로 이해했는지 확인하는 용도.

넷+하나 비교 결과

0. 한 줄 결론

숫자 오류는 D(제미나이) 1건뿐. 개념 오류는 없음. 넷 다 쓸 만하다. 최종 대본은 S(서버 클로드 순서도 2판)를 뼈대로 하고, B의 "문서 내부 충돌 2건 + 확인받고 싶은 것 3개"를 예상 질문에 넣고, A의 "바뀌지 않은 것" 열과 C의 미정 목록(코드 O-번호), D의 영역별 런 수 소계를 가져오면 된다.

1. 숫자 오류 (원문 대비)

AI	항목	그 AI 값	원문 값	어디
D 제미나이	144조합 전부 5-fold 하면 몇 런	"약 3,600회 이상" (Q9)	원문에 없음. 계산하면 $144 \times 4 \times 5 = 2,880$ (S 대본·B도 2,880)	06 § 4, 파일럿 § 6
A GPT	M2~M5 행	표가 C크기 의 세로줄 때문에 깨져서 "결정하는 것/안 되는 것" 칸이 사라짐	형식 오류. 내용 누락	[1] 단계표
A·B·C·D 공통	—	런 수 2,304 / 576 / 192~368 / 3,072~3,248 / 3,184~3,360, 분할 장수표, C 12~23, C1 48, 파일럿 0 64	전부 일치	—

B의 합산(파일럿 964 · 본실험 3,859)은 원문에 없지만 계산이 맞다($239+200+25+500$, $956+801+100+2,002$). D의 영역별 소계(파일럿 $2,416 = 48+64+2,304$ · 본실험 $768 \sim 944$)도 맞다.

2. 개념 오류

없음. 넷 다 아래 핵심을 맞게 썼다.

- 파일럿 20%는 본실험에 재사용 금지 · C는 파일럿에서만, AUB로 · M1 결과로 C 변경 금지 · 두 승자 구분과 최종 권장 = Cross-validated · P 점수 = 시험 fold Dice(체크포인트는 검증 fold) · Friedman 블록 4 · 효율은 보고만.

주의 1건 — D 제미나이 발표 대본 3절: "파일럿 0 ... 조기종료 규칙 및 체크포인트 선택 프로세스를 완전히 동결하게 됩니다" 라고 단정. 원문(결정 30, 파일럿 § 1)은 파일럿 0의 결정 권한을 **미정**으로 둬. D 자신의 표에는 미정이라고 맞게 써놓고 대본에서 단정한 것. 발표에서 이렇게 말하면 교수님이 바로 잡으실 것.

3. 넷이 갈리는 지점과 판정

쟁점	A	B	C	D	S	원문 판정
결정 13(VMamba-T 동결) 상태	해소로 읽음(00 우선)	해소로 읽고 충돌을 명시	언급 없음	미결로 나열	해소	해소가 맞음. 안내.md 표는 "13 미결"인데 00 § 4 는 "해소(v2 s1l8, SHA-256, backend)". 정본 규칙 2(충돌 시 00 우선). 안내.md 표가 낡은 것 → 교수님께 알릴 것
P 점수를 재는 fold	시험 fold	시험 fold + "00 § 1 본문은 validation 이라 쓰" 충돌 지적	시험 fold	시험 fold	시험 fold	시험 fold 가 맞음 (결정 16, 파일럿 § 4). 00 § 1 의 "파일럿 validation Dice" 는 3-fold 시절 문장이 남은 것 → 교수님께 알릴 것
복숭아 파일럿 학습 장수	12~13	12~13	12~13	12~13	12~13	06 § 4 는 "약 17장"(3-fold 시절 값), 01 § 3 은 12~13(4분할 실측). 06 이 낡음 → 교수님께 알릴 것

쟁점	A	B	C	D	S	원문 판정
"이 설계가 답하려는 질문 4개"	자체 작성	자체 작성	자체 작성	자체 작성(효율 트레이드오프 포함)	교수님 02 § 5 원문	입력 묶음에 02 문서가 없어서 넷 다 지어냈다. 원문 4개 = ①실용 순위 ②구성요소 효과(좋은 백본은 디코더 바뀌어도 좋은가) ③상호작용(부품의 합인가 공합인가) ④세대·데이터 조건(최신 이득이 소형·밀집·가림·저표본에서 재현되는가). 효율은 질문이 아님(보고만). → 01_input 에 02 § 5 를 추가함(이번에)
순서도 모양	파일럿·본실험 subgraph, 직선	subgraph + 두 승자 + 동결 마름모 + "M1→C 변경 금지" 점선	직선 한 줄	subgraph + 영역별 런 수 소개	두 영역 + 두 승자 + 보고	취향 문제. 발표용은 B 나 S
논문에 쓰면 안 되는 5개	00 § 8 계열(전수조사·직교· 흡수·3-fold·검출력)	안내 5개 + 원고	5-fold·전수조사·검출력 12.6%· 1.082·5.7089장·12.6%	전부 원문에 있는 표현이라 다 맞음. 교수님이 "5개"라고 하신 건 안내.md 「잇으면 안 되는 것」 이므로 S/B 가 가장 가까움		

4. 각 AI 가 잘한 점 (다른 데 없는 것)

- **A GPT**: 변경표에 "바뀌지 않은 것" 열을 뒤서 3-fold→4분할이 20/80·main 5-fold 를 안 건드렸음을 한눈에 보임. 00 § 8 의 금지 표현(직교 taxonomy, 흡수·대체·완전중복)까지 챙김.
- **B 로컬 클로드**: 문서 내부 충돌 2건(결정 13, screening 점수 fold)을 스스로 찾아 "확인받고 싶은 것 3개" 부록으로 뺌. 파일럿 실측(best epoch 113~685, best vs 800 차이)을 Q6 에 씬. 합산 값에 (합산) 표시.
- **C 딥시크**: 가장 짧고 표가 깔끔. 미정 목록을 코드 O-1·O-6·O-7·O-8·O-9·O-10·O-11 번호까지 정확히 씬. 5분 대본이 초 단위로 딱 맞음.

- **D 제미나이:** 순서도에 영역별 런 수 소계(파일럿 2,416 / 본실험 768~944). 빈 전경 Dice 규칙(둘 다 빈 마스크 = 1, 한쪽만 = 0) 질문 Q8 은 다른 셋에 없음.
- **S 서버 클로드:** 02 § 5 의 진짜 연구 질문 4개, 파일럿0 포도 16런 표, "왜 4분할로 바꿨나" 사유, 09-08 vs 09-11 비교표. 단 내부 충돌 지적은 없었음 → B 에서 가져와야 함.

5. 최종 채택안

빠대 = S 의 260912_실험설계_순서도_2판.md 대본 (숫자가 최신이고 연구 질문 4개가 교수님 원문). 여기에:

- B 의 부록 3개를 예상 질문에 추가 — 결정 13 상태, screening 점수 fold 표현, 파일럿0 결정 권한. 이 셋은 **교수님께 여쭙볼 것**으로 발표 끝에 말하면 "이해한 바대로 설명"에 딱 맞음.
- 06 § 4 "복숭아 약 17장"이 낡았다는 것도 같이 여쭙기.
- A 의 "바뀌지 않은 것" 한 줄: "20/80 소속·본실험 5-fold·group 은 v2 그대로".
- D 의 소계 한 줄: "파일럿 쪽 2,416런, 본실험 쪽 768~944런".
- C 의 미정 목록에서 코드 O-1(슬라이딩 추론 0건)·O-9(augmentations.py:340 두 분기 CenterCrop)를 "지금 막고 있는 것"으로.
- D 의 대본처럼 "파일럿0 로 규칙을 동결한다"고 단정하지 말 것. "동결할 재료를 모으는 단계, 무엇을 결정할지는 교수님 확정 대기"로.

→ 이 6개를 반영한 것이 260912_실험설계_순서도_2판.md **최종 수정 2026-09-12 18시 판**.

6. 이번 비교로 드러난 묶음의 빈틈

- 01_input 에 260905_02_모델_선정.md 가 없었음 → § 5(연구 질문 4개)를 이번에 추가. 다음 라운드부터는 넷도 진짜 질문을 쓸 수 있음.
- 원문 자체의 낡은 문장 3곳: 안내.md "13 미결" · 00 § 1 "파일럿 validation Dice" · 06 § 4 "복숭아 약 17장". 셋 다 09-11 변경 전 문장이 남은 것. 교수님께 알려드릴 것(사람).

7. 추기 (2026-09-13)

- 교수님이 09-13 00:11 에 파일럿0 64런을 v2 로 재실행(결정 31, 구간별 체크포인트). 위 비교는 09-12 원문 기준이므로 "파일럿0 결정 권한 미정" 판정은 이제 부분적으로 낡음 — 결정 31 이 목적(epoch 예산 판정)을 명시. 안내.md O-1(슬라이딩 추론)도 09-13 에 "[완료] 있음"으로 바뀜. 넷의 결과에 있는 "O-1 0건"은 09-12 기준으로는 맞았음.